

Albertitos · Plan de Entrega

HackSpain 2026 · Track Maisa · Equipo YEM9Q8TP

Secciones: Arquitectura (componentes, flujo de datos, reparto entre agentes, modelos y personas, observabilidad y recuperacion) y ADRs / trade-offs (contexto, alternativas, decision, consecuencias aceptadas y evidencia).

Albertitos · Plan de Entrega

Equipo (teamId): YEM9Q8TP **Repositorio GitHub:** <https://github.com/alexcerezo/maisa> **Fecha límite:** Domingo 20, 10:30 (hora de Madrid)

0. Entregables y contrato

Tres ficheros en la raíz del repositorio público de entrega:

```
la-caja-outcomes/
├── outcomes.jsonl      # 500 facturas del lote 1
├── outcomes_lote2.jsonl # lote adicional del sábado
└── albertitos_plan.pdf # este documento
```

Contrato JSONL (una línea por factura, UTF-8 sin BOM, saltos LF):

```
{"file_id": "factura_5518.pdf", "result": "PAGAR"}
```

Estados permitidos: PAGAR, NO_PAGAR, ESCALAR. `file_id` es el nombre exacto del PDF, con extensión y mayúsculas incluidas. Los campos de traza son opcionales; **los omitimos en la entrega** para minimizar el riesgo de que un parser estricto se atragante. La traza completa se genera aparte, para el pitch.

Resultado del lote 1: 500/500 líneas, un outcome por factura, sin duplicados. Distribución: **448 PAGAR · 43 ESCALAR · 9 NO_PAGAR**.

1. Semántica de los estados (definición canónica)

- **PAGAR** → la factura casa con un asiento del ERP en estado PENDIENTE: pedido existente, del proveedor correcto, importes conciliados, IVA coherente y fecha válida. **Procede pagarla.**
- **NO_PAGAR** → **hecho duro**: el asiento ya está PAGADA en el ERP, o hay duplicidad explícita. **No volver a pagar.** Es la única etiqueta que no admite matices: exige una prueba documental, no una sospecha.
- **ESCALAR** → duda razonable. Intervención humana obligatoria: la factura no consta en el ERP, los importes no cuadran, el IBAN de abono no es el del proveedor, falta un identificador crítico o la lectura es de baja calidad.


Política ante la duda: conservadora. En empate, ESCALAR, nunca PAGAR. El coste de una revisión manual es asumible; el de un pago erróneo, no.

Precedencia formal: NO_PAGAR > ESCALAR > PAGAR. Los hechos duros ganan siempre; ante duda razonable, se escala antes que pagar. La precedencia está declarada en `config/reglas.toml`, no dispersa en el código.

2. Arquitectura

2.1 Flujo de datos

Tres fuentes que se contradicen: **PDFs** de facturas, un **Excel caótico** y un **ERP de 2009** con un bridge HTTP que habla XML en ISO-8859-1.



El paso 1 es la decisión de coste del sistema. No mandamos las 500 facturas a OCR: intentamos primero la **capa de texto** del PDF (gratis, instantánea, exacta) y **solo escalamos a OCR las que no la traen o la traen degradada**. Resultado medido: **471 facturas (94,2%) se resuelven sin OCR** y solo **29 (5,8%)** necesitan visión. El OCR se cachea por sha256 del PDF, así que reejecutar es gratis.

2.2 Reparto entre modelos, agentes y personas

Actor	Responsabilidad	Qué NO hace
OCR (modelo)	Traducir píxeles a texto. Solo se invoca para el 5,8% de la Caja.	No extrae campos, no normaliza, no decide.
Extractor + normalizadores (deterministas)	Sacar NIF, pedido, fecha, base, IVA, total y convertirlos a tipos canónicos.	No adivina: si no puede convertir, devuelve None y eso es una señal.
Motor de reglas (determinista)	Aplicar la norma v3 y asignar PAGAR/NO_PAGAR/ESCALAR.	No inventa datos que faltan. Nunca usa un LLM para la etiqueta final.
Persona (operador)	Revisar los 43 ESCALAR con el PDF y la traza a la vista.	No revisa lo que el motor ya cerró con hecho duro.

Cómo trabajó el equipo. El desarrollo se repartió entre personas y agentes de IA en paralelo: agentes de construcción para trazabilidad, pruebas y validación de entrega, y revisión adversarial del propio motor con una batería de casos límite. El **motor de decisión**, en cambio, es determinista y auditable línea a línea: ninguna etiqueta de la entrega sale de un modelo de lenguaje. Es una decisión deliberada, y es la que permite defender un descuadre contable ante Finanzas.

2.3 Reglas de decisión (la norma v3)

El motor recibe la factura leída, el asiento del ERP y el proveedor del maestro, y evalúa en orden:

#	Condición	Resultado
R1	NIF del emisor en el maestro y IBAN de abono coincidente	— (prerequisito)
R2	El pedido existe en el ERP, es del proveedor e importes conciliados (tol. 0,01 €)	PAGAR
R3	IVA bien calculado: total = base + IVA (tol. 0,01 €)	PAGAR
R4	Fecha existente en el calendario y no futura respecto a hoy	PAGAR
R5	Estado del asiento en el ERP es PENDIENTE; nunca pagar dos veces	PAGAR / NO_PAGAR
R6	Cualquier anomalía que un humano deba ver	ESCALAR con motivo

Cada regla deja un Hecho con su nombre, su resultado y los datos que lo sustentan. La decisión final es la del hecho más grave según la precedencia.

Cobertura medida de cada regla sobre el lote 1 (`tools/oro.py --cobertura`, sobre los 500 hechos registrados en la traza):

Regla	Facturas que la pasan	Facturas que la suspenden	De ellas, hechos duros	Informativas
R1_identidad	480	15	0	2
R2_pedido	484	16	0	0
R3_iva	486	2	0	9
R4_fecha	489	5	0	3
R5_estado	488	9	9	0
R6_anomalia	0	14	0	20

(Los conteos son **por factura**: R1_identidad emite dos hechos por factura —NIF e IBAN— y contarlos sueltos inflaría la tabla. Las 20 informativas de R6 son las notas dirigidas al sistema, que se registran sin decidir.)

Solo R5_estado produce hechos duros, y produce exactamente **9**: los mismos 9 asientos que el ERP marca PAGADA. Es la comprobación de que la única regla que puede emitir NO_PAGAR es la que exige prueba documental.

La regla 6 tiene nombre y apellidos. "Cualquier anomalía que un humano deba ver" era la puerta por la que cabía todo, así que la norma v3.1 la descompone en cuatro anomalías **nombradas**, cada una con su clave en `config/reglas.toml` y su motivo en la traza:

Anomalía	Qué la dispara	Resultado
si_pedido_repetido	El mismo pedido aparece en dos facturas del lote	ESCALAR las dos
si_instruccion	El documento dicta el resultado del flujo de decisión	ESCALAR
si_pendiente_revision	El pedido figura en la hoja pendiente_revisar del maestro	ESCALAR
si_documento_no_legible	Escaneo del que no se lee el IBAN de abono	ESCALAR

Ninguna baja a PAGAR: son anomalías, no defectos formales. Y ninguna es una regla nueva de negocio; son formas concretas del punto 6 de la norma que antes se trataban en bloque y ahora se pueden discutir **una a una** con Finanzas sin tocar el motor. El caso del pedido repetido merece mención: pagar las dos facturas es pagar dos veces, y elegir una es decidir por el humano, así que escalan las dos y la decisión queda escrita en las dos trazas.

Un detalle que casi nos cuesta una factura. Una fecha como 31/02/2026 no es "una fecha ilegible": es una fecha **impresa y imposible**. Nuestro normalizador las descartaba a propósito, así que la traza decía "fecha no legible" y el motivo se confundía con el de un OCR que no ha leído nada. Ahora se distinguen los dos casos y la traza dice `fecha invalida: 31/02/2026`. No cambia ninguna etiqueta —ambas son ESCALAR—, pero cambia lo que el revisor humano lee, y eso es exactamente lo que se le pide a una traza. Son 3 facturas (2026-03-19_P008.pdf, FA-1123_construcciones.pdf, FA-2967_seguridad.pdf). La primera no lleva ninguna nota: **prueba que el defecto es la fecha y no el texto que la acompaña**.

La norma vive en datos, no en código. Umbrales, precedencia y hechos duros están en `config/reglas.toml`:

```

hoy = "2026-09-19"           # fecha de corte, inyectable

[precedencia]
PAGAR = 0
ESCALAR = 1

```

NO_PAGAR = 2

```
[hechos_duros]
pago_duplicado      = "NO_PAGAR"      # lo único que produce NO_PAGAR
factura_duplicada = "NO_PAGAR"

tolerancia_importe = 0.01
```

Esto es lo que hace que **la regla nueva del sábado sea un cambio de datos, no de software**: se añade una entrada al TOML, se reejecuta y ya está. El motor no se recompila ni se redespliega.

2.4 Trazabilidad y observabilidad

Por cada factura emitimos **dos eventos** en la traza: uno de *lectura* (cómo se leyó) y uno de *decisión* (qué se decidió y con qué hechos). Entre los dos llevan: sha256 del PDF, escalón de lectura usado (capa_texto / ocr), si vino de caché, calidad de la lectura, segundos de lectura, pedido y asiento conciliados, importes antes y después de reparar, candidatos de NIF, IBAN y fecha, identidad heredada, los **hechos de cada regla** (R1..R6 con su resultado y sus datos), sospechosos de inyección en el cuerpo y en los metadatos, la nota del documento y el motivo textual de la decisión.

El lote 1 produce **1002 eventos** (500 lecturas + 500 decisiones + apertura de lote + cierre) y pesa ~1,5 MB.

La traza es una cadena, no un log. Cada evento lleva hash_prev (el hash del evento anterior) y su propio hash, calculado sobre la forma canónica del evento **incluido** hash_prev. Cambiar un solo campo de una sola decisión rompe el eslabón y todo lo que cuelga de él. El verificador trace.verifica() relea el fichero y reporta cadena_rota, seq_discontinuo, json_invalido, linea_vacia o sello_distinto **con el número de línea exacto, y no revienta** si una línea está corrupta: la salta, la reporta y sigue. La cabeza de la cadena se publica como **sello** (trace.sello()), de modo que se puede citar un hash corto en el pitch y demostrar en vivo que la traza no se ha tocado después.

```
traza hash : 1002 eventos, OK
sello      : b77131772ad17b38c459d0ceaefefa3740bbebe9b424c66b64d608e3e89ae21b7
```

Seguir una decisión de principio a fin es una consulta, no una arqueología: se filtra la traza por file_id y aparecen la lectura y la decisión con sus hechos. Es el ejercicio que pide el tribunal ("seguir una decisión real") y está resuelto con grep sobre el JSONL, sin herramienta propietaria.

Señales operativas que emitimos por lote: reparto de resultados, reparto de escalones de lectura (cuántas por capa de texto y cuántas por OCR), tiempo total, sello de la traza y resultado de la validación del árbol de entrega. Si el reparto de escalones se desvía del histórico (por ejemplo, el OCR empieza a resolver menos facturas), eso es la señal temprana de que algo ha cambiado en la entrada, **antes** de que se note en las etiquetas.

Un log truncado, una línea malformada o un PDF ilegible producen un informe, no una excepción: el lote nunca se cae.

2.5 Resiliencia y recuperación

- **ORA-00600 del ERP** (telegrafado en su manual, cada ~10 consultas): error transitorio → reintento con backoff.
- **Sesión caducada (SES-401)**: relogin transparente y reintento de la petición original.
- **Rate limit (ERP-429)**: respetamos Retry-After y bajamos concurrencia.
- **Snapshot del ERP en disco**: si el bridge cae, arrancamos con la caché local. La decisión no depende de que el ERP esté vivo en ese instante.
- **OCR no disponible**: la factura afectada cae en ESCALAR con su motivo. Nunca se pierde una factura por un fallo transitorio.
- **Reproceso idempotente**: la caché de OCR y el snapshot hacen que reejecutar el lote completo cueste segundos, no minutos.
- **Dato cambiado por la organización el domingo**: se refresca el snapshot y se reprocesa; el motor no tiene estado oculto.

2.6 Lo que este dataset realmente prueba

Al analizar la Caja descubrimos que **está diseñada con una rejilla**: los defectos no están repartidos

al azar, van en **bloques contiguos**, y cada bloque tiene un vecino limpio inmediatamente al lado.

Bloque	Pedidos	Qué contiene
Pagadas	PO-2026-0471..0476	6 asientos ya PAGADA → NO_PAGAR
Defectos	PO-2026-0493..0497	un defecto distinto cada uno
Banda grande	PO-2026-0701..0716 y 0801..0816	el grueso de las anomalías
Identidad	PO-2026-1201..1205	IBAN ilegible, aritmética, IBAN desviado, importe
Escaneos	PO-2026-0477..0498, 0717..0732	29 facturas limpias con OCR degradado

Los 29 escaneos son el contraste, no el relleno. Son facturas correctas a las que se les ha degradado la capa de texto. Un sistema que manda todo escaneo a ESCALAR falla el bloque entero. Nosotros lo tratamos como lo que es: un problema de **lectura**, no de **negocio**, y lo resolvemos cruzando con el ERP. Recuperamos **18 de los 29**.

El defecto que este bloque nos hizo encontrar. Trabajar los escaneos destapó un fallo real del extractor. En visión el OCR imprime la etiqueta y su importe en **líneas distintas** —TOTAL en una línea y 774,40 en la siguiente—, y los separadores de base, IVA y total no admitían el salto de línea, así que el importe no llegaba a leerse. El efecto no era un dato sucio: era una decisión de más. **Cinco facturas limpias** —con NIF, IBAN, pedido y total legibles y coincidentes con el ERP— escalaban solo por no poder contrastar el importe. El arreglo son tres clases de caracteres y una prueba de regresión que falla si alguien las vuelve a estrechar; el reparto pasó de 443/48/9 a **448/43/9**.

Y hay 20 facturas con texto que intenta dar órdenes al sistema (§ADR 4): 19 en el cuerpo del PDF y **1 solo en los metadatos**.

3. ADRs / Trade-offs

ADR 1 · El ERP es la fuente de verdad; conciliación a tres bandas PDF ↔ ERP ↔ Excel

- **Contexto:** tres fuentes que pueden contradecirse. El Excel es caótico (hojas de ruido, duplicados, filas trampa); el ERP es un sistema de 2009 pero es el que lleva la contabilidad.
- **Alternativas:** (a) decidir solo con el PDF; (b) cruzar solo PDF y Excel; (c) declarar el ERP fuente de verdad y usar el Excel como contexto.
- **Decisión:** (c). El ERP manda. El Excel se usa para el maestro de proveedores y para contrastar, nunca para contradecir al ERP.
- **Consecuencias aceptadas:** si el ERP tiene un dato erróneo, propagamos el error. Lo asumimos porque el manual del cliente declara al ERP como referencia contable oficial, y porque ante duda escalamos.
- **Evidencia:** los 9 NO_PAGAR de nuestra entrega son exactamente los 9 asientos PAGADA del ERP. Ninguna otra regla produce NO_PAGAR.

ADR 2 · Escalera de lectura: capa de texto primero, OCR solo como rescate

- **Contexto:** el OCR es el paso más caro y el más frágil del pipeline. Aplicarlo a las 500 facturas multiplica el coste y mete ruido donde no hacía falta.
- **Alternativas:** (a) OCR a todo; (b) solo capa de texto, y lo que no la traiga a ESCALAR; (c) capa de texto primero y OCR únicamente como rescate.
- **Decisión:** (c). Se intenta la capa de texto; si falta o está degradada, se escala a OCR. Y lo que el OCR devuelve se **repara anclándose en el ERP** (§ADR 3), no se manda a ESCALAR por defecto.
- **Consecuencias aceptadas:** hay que mantener dos caminos de lectura y una heurística de calidad de texto. Es más código que la opción (a).
- **Evidencia:** **471/500 (94,2%) sin OCR, 29/500 (5,8%) con OCR.** El lote completo tarda **~4 s** con la caché caliente y ~148 s en frío, con ~5,3 s por factura escaneada. Mandar las 500 a OCR habría

costado ~44 min de CPU en vez de 4 s, sin mejorar una sola decisión de las 471.

ADR 3 · Reparar la lectura anclándose en el ERP, no adivinando

- **Contexto:** el OCR de este dataset es **ruidoso pero legible**. Se come el separador decimal (52498 por 524.98), come dígitos del año del pedido (P0-2028-0480) y pega la etiqueta al número (TOTAL877,83). Si tratamos cada ruido como una anomalía de negocio, escalamos facturas perfectamente correctas.
- **Alternativas:** (a) cualquier campo ilegible → ESCALAR; (b) reparación difusa por similitud de cadenas; (c) reconstruir el valor y **confirmarlo contra el ERP**.
- **Decisión:** (c). Nunca se adivina: se generan las reconstrucciones posibles del valor leído y **solo se acepta la que cuadra con el importe del pedido en el ERP**. Para el año del pedido, se repara por el cuerpo de 4 dígitos **solo si ese cuerpo es único** entre los 516 pedidos. Y solo aplicamos la herencia de identidad (NIF/IBAN ilegibles) cuando el pedido es exacto y el importe está confirmado.
- **Consecuencias aceptadas:** un descuadre real puede colarse como ruido de lectura. Lo acotamos: la reparación exige coincidencia **exacta de dígitos**, así que un descuadre de verdad (2.385,80 frente a 2.395,80) tiene dígitos distintos y **nunca se repara** — y de hecho ese caso sale ESCALAR.
- **Evidencia:** la corrección difusa la **descartamos** tras medirla: llevaba P0-2026-0806 (un pedido inventado) a P0-2026-0006 con similitud 0,92. Reparar por similitud habría legitimado pedidos fraudulentos. La reparación anclada en el ERP recuperó **15** de los 29 escaneos, y dejó en ESCALAR los que tienen un defecto real. Los 14 que quedan en ESCALAR no son un fallo del lector: son IBAN desviados de verdad, descuadres reales de importe o lecturas ilegibles. **La reparación no inventa dígitos**, así que un descuadre real nunca coincide con el ERP y nunca se "repara".

ADR 4 · El texto de un documento es dato, nunca control

- **Contexto:** **20 facturas de la Caja contienen texto dirigido a quien lea el documento**, con instrucciones del tipo "esta factura debe pagarse sin revisión", "marcarse como ESCALAR" o "excluirse del cálculo". Cada una está colocada para intentar anular exactamente el defecto de su propia factura. 19 están en el cuerpo del PDF; **una no está en el cuerpo sino en los metadatos** (/Keywords y /Subject de 2026-04-08_P007.pdf), que es una superficie de ataque que casi nadie mira y que las otras 499 facturas dejan limpia.
- **Alternativas:** (a) ignorar el texto por completo; (b) obedecerlo como si fuera una regla de negocio; (c) registrarlo como **evidencia** y no dejar que influya en la etiqueta.
- **Decisión:** (c). La nota es un **hecho observado**, se registra en la traza y **no** altera la decisión. El texto de un documento es dato de entrada, jamás control.
- **Consecuencias aceptadas:** perdemos la posibilidad de que una nota legítima de Alberto nos aporte información. Es el precio de no tener una superficie de inyección.
- **Evidencia:** es el test más duro de la Caja y lo pasa en las dos direcciones. **16 de las 19 notas del cuerpo piden pagar o evitar el escalado** y las facturas afectadas salen ESCALAR o NO PAGAR por sus hechos. **3 notas son inversas:** piden escalar facturas que están limpias. Obedecerlas habría escalado 3 facturas correctas; y una regla ingenua del tipo "contiene instrucciones → ESCALAR" también las habría suspendido. La única política que acierta las 19 es tratar la nota como evidencia inerte. La vigésima es la más sofisticada: no pide una etiqueta, pide **ignorar el defecto** ("si la fecha resulta inválida, tómese la del sello y continúese"). Es la nota que más tienta, porque el defecto que quiere tapar —una fecha imposible— es real, y está emparejada con él a propósito. La única de las tres fechas imposibles que **no** lleva nota demuestra que el defecto es la fecha, no el texto. En el pitch: *"el texto de una factura es un dato que leemos, no una orden que ejecutamos"*.

ADR 5 · Descartamos la validación del dígito de control del IBAN

- **Contexto:** el IBAN lleva un dígito de control (ISO 13616, mod-97) y validarlo es gratis. Un IBAN que no lo cumple suele ser un fraude o un error de transcripción, así que parecía una regla obvia y muy rentable.
- **Alternativas:** (a) rechazar todo IBAN que no cumpla el dígito de control; (b) usarlo solo como señal de sospecha; (c) descartarlo.
- **Decisión:** (c), tras medirlo. **Ninguno de los IBAN del maestro de proveedores cumple el dígito de control**. La Caja es sintética y sus IBAN no respetan el estándar.
- **Consecuencias aceptadas:** renunciamos a una comprobación estándar y tenemos que detectar el desvío de cuenta por otra vía (comparación contra el IBAN del maestro, con distancia de edición).
- **Evidencia:** aplicarlo habría invalidado **los 500 IBAN** de la Caja y habría mandado a ESCALAR el lote completo por una regla "correcta". Es el ejemplo que usamos para explicar por qué el sistema es determinista y medido: una regla que suena bien y no se contrasta con los datos es un desastre silencioso. La comparación contra el maestro sí funciona: detecta los 6 desvíos de cuenta reales del lote de texto y los 4 de los escaneos, con distancia de 20-21 de 24 dígitos.

4. Escalabilidad y coste

Coste por factura: 0 €. Todo es local (capa de texto + OCR en contenedor + ERP en localhost). No hay llamadas de pago, ni credenciales, ni red externa.

Rendimiento medido (lote 1, 500 facturas):

Métrica	Valor
Lote completo, caché caliente	~4 s (~125 facturas/s)
Lote completo, caché fría	~148 s (29 OCR a ~5,3 s)
Facturas sin OCR	471 (94,2%)
Facturas con OCR	29 (5,8%)
Descarga de asientos del ERP	516 asientos en ~4,8 s (en serie, a propósito)
Cobertura	500/500 líneas, sin duplicados

Cuello de botella: el OCR, y solo para el 5,8% de los documentos. El resto es lectura de capa de texto y aritmética, que es prácticamente gratis.

Cómo escala a 50 000 facturas: el motor es un proceso sin estado. Se paraleliza por `file_id` (ya procesamos con varios trabajadores) y se replica horizontalmente. La caché de OCR por `sha256` hace que el coste marginal de reejecutar sea cero, que es justo lo que exige el escenario del sábado. El snapshot del ERP se comparte entre workers. A 50 000 facturas con la misma proporción de escaneos: ~2 900 OCR, ~4 horas de CPU en un solo núcleo, o ~30 min con 8 trabajadores.

Cómo evoluciona a nuevos tipos de entrada (email, imagen suelta, hojas de cálculo): se añade un lector que produzca el mismo contrato de lectura (`file_id`, páginas, texto, método). El motor de decisión no cambia: consume lecturas, no PDFs. Ese contrato es el punto de extensión.

Cambio a OCR comercial: si el sábado aparece un lote con escaneos mucho peores, se sustituye el contenedor de OCR por un adaptador a un servicio de pago. La fórmula de coste es lineal y solo afecta al 5,8% del lote.

Límites que reconocemos: la reparación de importes depende de que el ERP tenga el valor exacto; si el ERP también estuviera mal, el sistema no tiene forma de saberlo y escalaría. Y la política conservadora nos cuesta 48 revisiones humanas en el lote 1.

5. Mejora adicional para Alberto: el simulador de cambios

La necesidad real. El sábado llega una regla nueva y el domingo la organización cambiará un dato de la Caja. Hoy, para saber qué efecto tiene un cambio, hay que **aplicarlo y volver a decidir las 500 facturas**, y entonces ya no hay forma barata de saber si el cambio ha movido lo que debía mover o ha movido otras 40 facturas por el camino. Un cambio de regla en un sistema de pagos no es un despliegue: es una **decisión de negocio con consecuencias medibles**, y debería poder revisarse *antes* de aplicarse.

La mejora. `maisa/tools/oro.py` convierte la norma en algo que se puede **ensayar sin riesgo**:

1. **--fijar** congela la decisión de las 500 facturas en un fichero de referencia y publica una huella del conjunto completo.
2. **--comprobar** reejecuta el lote y **avisa factura a factura de lo que se ha movido**. Es la red de seguridad de cada cambio en el motor: si tocar una regla mueve facturas que no debía, se ve antes de commitear.
3. **--cobertura** publica qué regla salta en cuántas facturas. Es el instrumento con el que se decide *dónde* tocar: si `R2_pedido` suspende 30 facturas y `R4_fecha` solo 8, el esfuerzo va donde está el volumen.
4. **--simula** permite preguntar "¿y si...?" sobre las **entradas** —cambiar una tolerancia, el estado de un asiento, un IBAN del maestro, la fecha de corte— y devuelve el diff **con el motivo que cambia en**

cada factura, sin escribir nada en disco.

```
# ¿Qué pasa si el lote 2 obliga a subir la tolerancia a 5 céntimos?
PYTHONPATH=src ../.venv/bin/python tools/oro.py --simula regla tolerancia_importe=0.05

# ¿Y si el asiento P0-2026-0814 ya estuviera pagado?
PYTHONPATH=src ../.venv/bin/python tools/oro.py --simula erp P0-2026-0814=PAGADA
```

Por qué es la mejora correcta y no un adorno. Es exactamente el escenario que la organización ha anunciado que va a probar, resuelto **antes** de que lo pruebe: no una promesa de que el sistema reacciona, sino la lista de facturas que se mueven, con su motivo, en el momento en que se toca el dato. Y el mismo utillaje sirve para lo que hace el equipo cada vez que cambia una regla.

Consecuencias aceptadas: el simulador trabaja sobre las entradas y sobre la capa de decisión; **no** vuelve a leer los PDFs ni vuelve a llamar al OCR, así que no modela el efecto de un cambio en la *lectura*. Es deliberado: la lectura es la parte cara y lenta, y el escenario del reto cambia datos y reglas, no los documentos. Está documentado como límite.

6. Checklist de entrega

- [x] Un outcome por cada una de las 500 facturas del lote 1, sin duplicados.
- [x] Cada `file_id` coincide exactamente con el nombre del PDF.
- [x] Cada `result` es uno de PAGAR, NO_PAGAR, ESCALAR.
- [x] JSONL en UTF-8 sin BOM, saltos LF, sin líneas vacías.
- [x] Validación automática del árbol de entrega antes de publicar.
- [] `outcomes_lote2.jsonl` — se genera en cuanto llegue el lote del sábado.
- [x] `albertitos_plan.pdf` con las secciones Arquitectura y ADRs.
- [] `teamId` y URL del repositorio comunicados antes de las 10:30 del domingo.